



## CardioIA - Protótipo de Assistente Cardiológico Virtual

### Relatório Técnico de Desenvolvimento – Fase 4

- **Integrantes:**
  - Arthur Guimarães Alentejo - rm564810,
  - Michael Araujo Rodrigues - rm565452,
  - Nathalia de Almeida Vasconcelos - rm563510
- **Github:** <https://github.com/Fiap-RJ/TIAO-2026/tree/main/2TIAO/FASE4-CARDIOIA>

## INTRODUÇÃO

O presente relatório visa apresentar o trabalho desenvolvido na Fase 4 do CardioIA, projeto acadêmico do curso de IA com o do método PBL (Project Based Learning). Nesta fase o objetivo é processar exames simulados de eletrocardiograma (ECG) contendo 4 classes clínicas e construir uma solução de apoio à decisão médica de forma confiável e responsável.

## PRÉ-PROCESSAMENTO E ORGANIZAÇÃO DOS DADOS

O Dataset de imagens selecionado foi o mesmo da Fase 1 o *ECG Images Dataset*, disponível em: <https://www.kaggle.com/datasets/jayaprakashpondy/ecgimages/data>

- **Justificativa do Redimensionamento:** As imagens originais possuíam dimensões variadas de acordo com o sinal clínico capturado. Foram padronizadas para a resolução geométrica de 224x224 pixels usando a biblioteca OpenCV (cv2.resize), garantindo uma matriz de entrada fixa e compatível com arquiteturas convolucionais profundas.

- **Justificativa da Normalização:** A escala de intensidade de pixels foi convertida de inteiros [0, 255] para valores de ponto flutuante no intervalo [0.0, 1.0] dividindo os arrays por 255.0. Isso reduz a magnitude dos gradientes no backpropagation, acelerando a convergência matemática e evitando instabilidades numéricas no otimizador Adam.

- **Justificativa da Divisão dos Dados:** Para garantir a integridade metodológica e mitigar o *overfitting*, os dados foram estruturados em três partições: Treino (531 imagens) para o ajuste de pesos, Validação (133 imagens) para monitoramento fino durante as épocas e Teste (280 imagens) atuando como uma base inédita e isolada para validação final.

```
... --- Pré-processamento Concluído! ---  
Total de imagens para TREINAR a IA: 531  
Total de imagens para VALIDAR durante o treino: 133  
Total de imagens para TESTAR o protótipo final: 280
```

## TREINAMENTO E ANÁLISE COMPARATIVA DE MODELOS (CNN VS. VGG16)

- **Abordagem 1 - CNN Customizada (Do Zero):** Foi arquitetada uma rede sequencial leve com camadas convolucionais (Conv2D para extração de features locais como picos e inclinações das ondas do ECG), seguidas de subamostragem (MaxPooling2D) e regularização por Dropout(0.5). Esta rede apresentou uma performance notável, atingindo 93,23% de acurácia de validação, demonstrando alta adaptabilidade a padrões de linhas geométricas contínuas e malhas quadriculadas de ECG.


Epoch 15/15  
17/17 — 1s 52ms/step - accuracy: 0.9887 - loss: 0.0607 - val\_accuracy: 0.9323 - val\_loss: 0.2079

- **Abordagem 2 - Transfer Learning (VGG16):** O modelo pré-treinado no ImageNet, atingiu 71,43% de acurácia de validação e classificou 56 imagens erroneamente.

Epoch 15/15  
17/17 — 4s 237ms/step - accuracy: 0.5556 - loss: 1.0651 - val\_accuracy: 0.7143 - val\_loss: 0.9522


- **Análise do Resultado:** Os filtros congelados da VGG16 aprenderam no ImageNet a extrair características de imagens naturais complexas (formas orgânicas, texturas de animais, objetos tridimensionais). Sinais biomédicos bidimensionais como o ECG consistem em traçados abstratos e contínuos. Sem o descongelamento de camadas profundas (*Fine-Tuning*), os extratores da VGG16 falharam em discriminar os picos do ECG.

- **Análise das Matrizes de Confusão:** A diagonal principal do gráfico gerado pela CNN customizada concentrou a imensa maioria dos dados, demonstrando o sucesso do protótipo em separar Corações Normais de anomalias cardíacas severas. Embora a diagonal principal da matriz de confusão do modelo VGG16 tenha apresentado grande concentração, um modelo de IA para auxílio a diagnósticos médicos não deve apresentar grandes possibilidades de erros.



## INTERFACE DO NOTEBOOK INTERATIVO

Após o treinamento foi incluída uma etapa para a interação com o modelo através da inclusão de novas imagens para classificação e comparativo entre os modelos.



## **CONCLUSÃO E GOVERNANÇA EM SAÚDE**

Seguindo as diretrizes de governança em IA da Fase 4, o protótipo provou que modelos menores e focados no domínio médico podem superar modelos genéricos gigantescos. A solução respeita os princípios de confiabilidade e responsabilidade, estando pronta para ser integrada a interfaces interativas ou aplicações móveis seguras.